

Analysis of attention maps to relate how the memory state and observation history affect each other and the next action prediction in SRMT

Команда и распределение ролей


Работа выполнена командой в составе:

- **Кушнарев Олег:** разработка системы визуализации карт внимания и карты среды, включая интеграцию с фреймворком Rogema.
- **Беляев Александр:** обучение агентов, проведение 18 экспериментов с вариацией параметров, анализ паттернов внимания
- **Кривошеев Николай:** обучение агентов, проведение 18 экспериментов с вариацией параметров, анализ паттернов внимания.

Научный руководитель — **Алсу Сагирова**. Исследование базируется на архитектуре SRMT (Sagirova et al., arXiv), расширяющей идеи совместной памяти для мультиагентного обучения.

Введение

Работа посвящена исследованию влияния состояния памяти и истории наблюдений агентов на прогнозирование действий в архитектуре SRMT (Shared Memory for Multi-agent Lifelong Partnering). Основной инструмент анализа — визуализация карт внимания, полученных из self-attention и cross-attention слоев нейросетевой модели. Эксперименты проводились в симуляционной среде Rogema, где агенты перемещаются к целям в противоположных комнатах через узкий коридор переменной длины (3, 9, 15 единиц).



Среда Rogema

Методология

Архитектура SRMT основана на комбинации ResNet-энкодера и механизмов внимания

GPT-2. Модель использует:

- Текущее состояние среды;
- Данные за 8 последних шагов наблюдения;
- Локальную память агента;
- Глобальную память системы.

Для извлечения весов внимания модифицирован вывод трансформера: веса фиксируются в логах вместе с выходными действиями. Реализована визуализация относительных координат агентов (от начальной позиции) с помощью интерактивных карт на Plotly.

Экспериментальный дизайн включал 18 сценариев с вариациями:

- Тип награды (Sparse, Moving Negative);
 - Конфигурация памяти (полная, без глобальной памяти, без памяти);
 - Длина коридора (3, 9, 15).
- Построено 118 карт внимания, анализировались критические точки: встреча агентов, пропуск одного агента другим, вход в комнату или коридор, достижение цели.

Разработка, визуализация

1. Извлечение весов внимания

Архитектура SRMT объединяет ResNet-энкодер с механизмами внимания GPT-2. Для доступа к весам:

- Модифицирован вывод трансформера: при вызове `core_transformer` активирован флаг `output_attentions=True`, возвращающий тензоры весов.
- Веса сохраняются в словаре логов вместе с действиями и состояниями памяти.
- Данные записываются для каждого шага симуляции (8 последних наблюдений).


2. Преобразование координат

- В логах используются **относительные координаты** от начальной позиции агента.
- Для привязки к абсолютной карте: начальные позиции извлекаются из отдельных логов симулятора, выполняется аффинное преобразование.

3. Визуализация

- Библиотека **Plotly** создает интерактивные карты:
 - Верхняя строка / красный цвет: агент 1.


- Нижняя строка / синий цвет: агент 2.
- Слайдеры для пошагового просмотра:
 - Карта среды с позициями агентов.
 - Heatmap весов self-attention (внутриагентное внимание).
 - Heatmap cross-attention (внимание к памяти других агентов).



Результаты


Общие паттерны внимания:

1. Начальное внимание агентов зависит от типа памяти. Без глобальной памяти фокус внимания сужается, что сохраняется при разных длинах коридора.
2. При движении по коридору векторы внимания смещаются к старым наблюдениям. При проходе агента происходит сброс внимания с последующим накоплением новых данных.
3. Cross-attention равномерно распределен между всеми векторами памяти.




Ключевые наблюдения:

- **Паттерн пропуска агента:** При пропуске другого агента (красным агентом синего) внимание постепенно фокусируется на моменте пропуска. Паттерн воспроизводится для всех длин коридора.



- **Паттерн движения по коридору:** В неизменяемой обстановке коридора внимание смещается к самым старым ячейкам памяти, включая данные о входе в лабиринт.



- **Аномальный выброс:** Обнаружен случай резкого переключения внимания красного агента (Head 1 и 3) на данные 2–4 шагов назад. Это требует дополнительной верификации.

Проверка гипотез:

- Агенты фиксируют внимание на моменте встречи в коридоре, особенно при длине 15.
- Красный агент всегда пропускает синего, после чего корректирует траекторию.
- Без глобальной памяти агенты "блуждают" при входе в целевую комнату.
- Moving Negative-награда приводит к остановкам в коридоре или отказу от входа.

Паттерн выхода из коридора.

Был проведен анализ карт внимания нейронной сети SRMT. В результате анализа была найдена закономерность, описывающая поведение агентов в моменте выхода обоих агентов из коридора.

Рассматривается ситуация, описанная на изображениях ниже. Изначально агенты встречаются в коридоре, как показано на рисунке 1. Далее агенты выходят из лабиринта, как показано на рисунке 2. Рассматривается ситуация, изображенная на рисунке 2.




Рисунок 1. Состояние среды, когда агенты вышли из коридора.




Рисунок 2. Состояние среды, когда агенты вышли из коридора.

Анализируемые карты внимания представлены на рисунках 3 и 4. На рисунке 3 представлена карта внимания агента 1, изображенного синим цветом. На рисунке 4 представлена карта внимания агента 2, изображенного красным цветом.




Рисунок 3. Карта внимания агента 1 (синего).




Рисунок 4. Карта внимания агента 2 (красного).

В данных картах на позиции с индексом 9 обозначено текущее входное изображение. На позициях с 1 по 8 содержится память агента о прошлых наблюдениях среды (прошлые 8 входных изображений среды, где на первой позиции самые старые, а на 8 позиции самые новые наблюдения). В позиции с индексом 0 содержится рекуррентная память агента.

В результате анализа была замечена закономерность. Если рассматривать карту внимания из Head 3 в агенте 2, то можно увидеть, что она ссылается на 5 позицию, это информация об итерации, которую видел агент 4 хода назад. Если рассматривать карту внимания из Head 1 в агенте 2, то можно увидеть, что она ссылается на 7 позицию, это информация об итерации, которую видел агент 2 хода назад.

Состояния среды 2 и 4 хода назад показаны в таблице 1, также на изображении справа представлено текущее состояние среды.

Таблица 1. Состояния среды, на которые обратила внимание нейронная сеть

Состояние 4 хода назад	Состояние 2 хода назад	Текущее состояние

По данным изображениям видно, что нейронная сеть в агенте 2 (красный) обратила внимание на место встречи двух агентов. Также агент 2 обратил внимание на кадр, где он видел целевую точку другого агента, куда должен прийти агент 1. Возможно, что агент 2 (красный) решает то, куда ему нужно двигаться дальше. Например, по данным изображениям можно сделать вывод, что двигаться влево нельзя, об этом подсказывает память нейронной сети на итерации 2 хода назад. Также возможно нейронная сеть попыталась понять, куда движется агент 1 (синий), посмотрев на данные 4 хода назад.

По приведенному анализу можно сделать вывод, что рассмотренная ситуация показывает, что агент пользуется своей памятью.

Анализ ответов Self-Attention после применения карт внимания к матрице значений.

Проанализированы выходные значения после self-attention, после применения карт внимания к матрице значений в слое attention. Основная цель заключается в анализе ответов нейронов на разные ситуации и того, какую информацию слою внимания берут из токенов.

Проведен анализ встречи агентов в коридоре, на изображении ниже представлена рассматриваемая ситуация.




Рисунок 5. Столкновение агентов в коридоре.

Были проанализированы выходные значения голов внимания слоя Self-Attention в агенте 1 (синий) и построены тепловые карты представленные ниже на рисунках 6 - 8.




Рисунок 6. Агент 1 (синий). До встречи.




Рисунок 7. Агент 1 (синий). Встреча агентов.




Рисунок 8. Агент 1 (синий). Спустя 2 итерации после встречи.

По представленным изображениям видно, что Heads 1 и 2 не среагировали на встречу агентов. Heads 1 и 2 практически не изменились в результате тестирования, есть небольшие резкие изменения отдельных значений, но закономерность не была выявлена.

В момент встречи агентов среагировала Head 0, изменилось состояние в ячейке 9, соответствующее входному изображению. В течение нескольких итераций после столкновения агентов Head 0 продолжает обращать внимание на ячейки 9 и 8, которые соответствуют текущему кадру из симуляции и кадру на предыдущем шаге.

Спустя 2 итерации после встречи произошли быстрые изменения в ответах Head 3. Изменения в Head 3 продолжаются до конца симуляции, независимо от наличия или отсутствия другого агента в поле зрения. По анализу ответов Head 3 видно, что до встречи с другим агентом в Head 3 был стабильный шаблон представленный на рисунке 6, после встречи с агентом Head 3 очень часто и сильно изменялся.

Краткий вывод: по представленному анализу было сделано предположение, что в агенте 1 (синий) Heads 0 и 1 отвечают за анализ пересечения с другими агентами.

Были проанализированы выходные значения голов внимания слоя Self-Attention в агенте 2 (красный) и построены тепловые карты представленные ниже на рисунках 9 - 10.




Рисунок 9. Агент 2 (красный). До встречи.




Рисунок 10. Агент 2 (красный). Спустя 2 итерации после встречи.

По представленным изображениям видно, что в ответах Self-Attention не произошло существенных и массовых изменений в Heads 0 - 3 в ответах агента 2. Есть резкие изменения отдельных значений, но четкой закономерности выявлено не было.

Краткий вывод: по представленному анализу было сделано предположение, что требуется дальнейший анализ выходных значений Self-Attention в агенте 2 (красный).

Заключение и перспективы

Подтверждена возможность интерпретации работы памяти агентов через карты внимания и тепловые карты. Обнаружены устойчивые паттерны, связанные с динамикой среды. Для углубления исследования предложены:

1. Разработка количественных метрик вместо качественного анализа.
2. Обучение автоэнкодера для проецирования векторов внимания на карту среды.
3. Кластеризация векторов внимания для выявления семантически значимых состояний.
4. Исследование агентов без планировщика движений.

Визуализация карт внимания доказала эффективность для диагностики поведения агентов в задачах с ограниченной наблюдаемостью. Результаты актуальны для улучшения архитектур памяти в мультиагентных системах.